

Analyse du Marché de l'Emploi IT au Maroc

Mexora RH Intelligence - Architecture Data Lake

Architecture Data Lake (Étape 1)

Document de conception

1. Justification des formats de stockage

Zone	Format	Pourquoi ce format?	Pourquoi pas les autres?
Bronze	JSON	Permet de stocker les données semi-structurées brutes (avec des tableaux imbriqués) exactement telles qu'elles ont été extraites, sans imposer de schéma.	Le CSV aplatirait la hiérarchie et casserait les listes. Le Parquet forcerait un schéma strict trop tôt.
Silver	Parquet	Format orienté colonne, fortement compressé et typé. Offre des performances de lecture exceptionnelles pour les filtrages des données nettoyées.	Le JSON serait trop lent et trop lourd. Le CSV ne conserve pas les types de données (int, dates).
Gold	Parquet	Idéal pour l'analytique et parfaitement optimisé pour être interrogé nativement et à très haute vitesse par DuckDB.	Le JSON et le CSV offriraient des performances d'agrégation beaucoup trop faibles.

Table 1 – Choix des formats par zone du Data Lake

2. Réponses aux questions de conception

1. Pourquoi conserver les données brutes en zone Bronze sans les modifier? Quels risques si on ne le fait pas?

La zone Bronze doit être immuable. Elle sert d'archive fidèle et garantit la traçabilité (*Data Lineage*). Si une règle métier change dans le futur ou si un bug corrompt la zone Silver, nous pouvons relancer le pipeline depuis Bronze. Si nous modifions les données dès l'ingestion, la donnée originale est perdue définitivement, rendant toute récupération impossible.

2. Qu'est-ce que le "schema-on-read"? En quoi est-ce différent du DWH("schema-on-write")?

Le schema-on-read (utilisé dans un Data Lake) signifie que la donnée est stockée dans son format natif et que la structure n'est appliquée qu'au moment de la lecture par l'analyste, offrant une flexibilité maximale. À l'inverse, le schema-on-write (utilisé dans un Data Warehouse) oblige à définir des tables strictes avant le chargement; toute donnée hors modèle est rejetée.

3. Comment définit-on la partition dans chaque zone?

- Zone Bronze (*par_source/par_mois*) : L'ingestion est technique. Séparer par source permet d'isoler rapidement un problème si le format d'une source change.
- Zone Silver (*par_ville/par_mois*) : Le partitionnement s'aligne ici sur les axes d'analyse métier du DRH. Filtrer directement sur le dossier cible évite de scanner toutes les données, accélérant drastiquement les requêtes géographiques.

4. Comment éviter que le Data Lake devienne un "Data Swamp"? Règles de gouvernance :

Un *Data Swamp* apparaît quand les données sont stockées sans contrôles. Pour l'éviter, il faut :

- Appliquer une ségrégation stricte des droits (seuls les Data Engineers modifient Bronze, les analystes lisent Gold).
- Implémenter des tests de qualité automatisés (*DataOps*) entre Bronze et Silver.
- Maintenir un dictionnaire de données à jour (ex : référentiel de compétences).